

(2) 3차년도 (2026)

3차년도의 목표는 1차년도에 개발한 AWSGMCMC(AWSGLD)를 이용한 베이지안 BSR-BSS keyphrase(핵심 문구) 추출 모델을 새로이 제안하고, 이를 이용하여 대량의 텍스트 데이터(문서 집합)로부터 미래 유망 토픽을 자동으로 탐지하는 프로세스(future topic auto-detection process, FADP)를 제안하고자 한다.

현재 생산되는 대량의 데이터로부터 미래 특성을 예측하거나 미래에 등장할 유망 기술을 탐지하는 것은 빅데이터 시대의 중점 과제 중 하나이다. 인공지능 기술이 발전되었음에도 현재까지의 미래 유망 기술 탐지는 데이터 분석 외에도 전문 인력의 식견이 필요하다. 이는 미래기술 탐지 영역이 증가할수록 필요한 전문 인력 또한 증가한다는 한계점이 존재한다. 따라서 전문 인력 의존성에서 벗어나기 위한 미래기술 자동 탐지 프로세스가 필요하다.

먼저, 미래 유망 토픽을 자동으로 탐지하는 프로세스에 이용되는 keyphrase 추출 및 핵심 문구 선택이 가능한 AWSGMCMC-BSR-BSS keyphrase 추출 모델을 제안한다. 즉, AWSGMCMC-BNTM를 이용한 그래프 기반 Bayesian semi-supervised(BSS) 모델을 통해 후보 keyphrase를 추출하고(WANG, 2020), FDR(false discover rate) 기반 AWSGMCMC-BSR(Bayesian Subset Regression; Liang et al., 2013)을 이용해 핵심 keyphrase를 선택한다.

베이지안 그래프 기반 BSS 모델에서는 구문 i 가 keyphrase로 관찰(예측)되었는지 여부를 나타내는 y_i 와 실제 keyphrase인지 여부를 나타내는 y_i^* 의 두 가지 라벨을 할당한다. π_i 는 구문 i 가 keyphrase 일 확률 $\Pr(y_i^* = 1)$, α_i 는 keyphrase가 관찰되지 않을 확률 $\Pr(y_i = 0 | y_i^* = 1)$ 이다. π_i 와 α_i 가 주어졌을 때, y_i 의 조건부 확률은 hidden 변수 y_i^* 의 완전 가능도(full likelihood)

함수를 적분하여 계산할 수 있다. 베이지안 프레임워크 하에서, 비지도 중요도 점수 θ 는 TextRank 등에서 얻을 수 있다. π_i 는 0과 1 사이의 확률을 갖고 중요도 점수 θ_i 는 모든 실수가 될 수 있으므로 logit 함수를 사용하여 π_i 와 θ_i 를 연결한다 ($\theta_i : \pi_i = \log \frac{\pi_i}{1-\pi_i}$). $\theta = (\theta_1, \dots, \theta_n)^T$ 의 선형 변환을 위해 다변량 정규 prior를 사용하고, 역 감마 분포 $IG(0.001, 0.001)$ 를 사용하여 $1/\sigma^2$ 를 근사화하고, α 에 균일 prior를 사용한다. 최종적인 keyphrase 추출을 위한 결합 사후 분포는 다음 식 (10)과 같다.

$$\begin{aligned} \psi(\theta, \alpha, \sigma^2 | \mathbf{y}) &\propto P(\mathbf{y} | \theta, \alpha) \pi(\theta | \sigma^2) \pi(\alpha) \pi(\sigma^2) \\ &\propto \prod_{i=1}^n \left[\frac{(1-\alpha)e^{\theta_i}}{1+e^{\theta_i}} \right]^{y_i} \left[1 - \frac{(1-\alpha)e^{\theta_i}}{1+e^{\theta_i}} \right]^{1-y_i} \times N(\theta; \theta_0, B^{-1}(B^{-1})^T \sigma^2) \times IG(\sigma^2; 0.001, 0.001) \end{aligned} \quad (10)$$

사후분포 (10)으로부터 주요 관심 파라미터(중요도 점수)인 θ_i 를 추출하기 위해 AWSGMCMC 알고리즘을 사용하고, 얻어진 θ 를 확률 척도로 변환하여 π 를 얻을 수 있다.

π 에 의한 후보 keyphrase 중 핵심 keyphrase만을 추출하기 위해 FDR 기반 AWSGMCMC-BSR 방법을 사용한다. 즉, AWSGMCMC-BSR-BSS keyphrase 추출 알고리즘은 아래와 같이 정리할 수 있다.

AWSGMCMC-BSR-BSS keyphrase 추출 알고리즘:

- (a) [초기화] TextRank 키워드 추출 방법의 결과를 이용하여 파라미터 초깃값을 설정한다.
- (b) [중요도 점수 θ 산출] BSS 사후분포 (10)을 기반으로 식 $p(\sigma^2 | \mathbf{y}, \theta, \alpha)$, $p(\alpha | \mathbf{y}, \theta, \sigma^2)$, $p(\theta | \mathbf{y}, \sigma^2, \alpha)$ 로부터 AWSGMCMC 알고리즘을 이용하여 σ^2, α, θ 의 표본을 생성시킨다.
- (c) [핵심 keyphrase 선택] 추출된 중요도 점수 확률 π 로부터 AWSGMCMC-BSR을 사용하여 최종 keyphrase를 선택한다. 변수선택 규칙은 주변포함확률 q_s 가 한계치 $\hat{q}$ 보다 큰 특징들을 찾는

것이다. 즉, $\hat{\xi}_q = \{x_s : q_s > \hat{q}, s = 1, \dots, P_n\}$ 을 ξ^* 의 추정치로 정한다. 한계치 $\hat{q}$ 를 결정하기 위해, 변수검사과정(sure variable screening)을 이용한 다중 가설검정방법을 제안한다. 먼저 $q_1, q_2, \dots, q_{P_n}$ 을 P_n 개 변수의 주변포함확률이라고 하고 $z_s = \Phi^{-1}(q_s) (s = 1, \dots, P_n)$ 를 주변포함점수(marginal inclusion score, MIS)라고 하자. 여기서 $\Phi(\cdot)$ 는 표준가우시안분포의 누적분포함수이다. 유의하게 큰 MIS를 가지는 특징을 찾기 위해 본 연구는 잡음(noise)과 변수들의 특징을 얻기 위해 MIS를 2성 혼합지수멩분포(two component mixture exponential power distribution)로 이용한다. 다음으로 $\hat{q} = \Phi(z_r)$ 에 상응하는 절단값(cutoff value) z_r 은 미리 정해진 유의수준에 따라 변수들의 FDR를 조절하면서 선택될 수 있다. $\Lambda_r = \{Z_s : Z_s \geq z_r\}$ 이 주어지면, FDR은 다음과 같이 추정될 수 있다:

$$FDR(\Lambda_r) = \frac{P_n \hat{w}_1 [1 - F(z_r | \hat{\nu}_1, \hat{\sigma}_1, \hat{\alpha}_1)]}{\#\{z_s : z_s \geq z_r\}}, \quad \# \{z_s : z_s \geq z_r\} \text{는 } z_r \text{보다 큰 MIS를 가지는 변수들의 개수이고 } F(\cdot) \text{는 지수멩분포의 누적분포함수이다. 또한 다중 가설검정을 위한 기준치를 결정하기 위해 } q\text{-value를 정의한다: } q_r^s(z) = \inf_{\{ \Lambda_r : z \in \Lambda_r \}} FDR(\Lambda_r).$$

마지막으로 본 연구는 AWSGCMC-BSR-BSS 알고리즘을 개발하고 이를 이용한 BSS keyphrase 추출 모델 추론을 통해 핵심 keyphrase를 구한 뒤, KISTI의 워크시그널 탐지 프로세스(양혜영 외 10인, 2021)를 기반으로 개선한 FADP 방법을 다음과 같이 제안하여 미래 유망 토픽 추론을 하고자 한다.

미래 유망 토픽 자동 탐지 프로세스(Future Topic Auto-Detection Process, FADP):

- (a) [keyphrase 추출] AWSGCMC-BSR-BSS keyphrase 추출 알고리즘을 이용하여 핵심 keyphrase를 추출한다.
- (b) [keyphrase 활동성 측정] 조건 기반 최근 활동성이 높은 keyphrase를 선별한다. (조건 임계값 조정 가능)
 - (b.1) TF-IDF 점수 ≥ 0.8
 - (b.2) 경향성 = 후반년도(최근) 빈도수 - 전반년도(과거) 빈도수 > 0
 - (b.3) 규모성 = 최근 빈도수 ≥ 9
 - (b.4) 활동성 = 최근 빈도수 / 전체년도 빈도수 ≥ 0.5
- (c) [keyphrase 그룹 자동생성] 1차년도에서 제안한 AWSGCMC-BNTM을 이용하여 keyphrase 그룹(토픽)을 생성한다.
- (d) [포커스 영역 설정] 네트워크의 중요도(가중치)가 높은 keyphrase 그룹을 포커스 영역으로 설정한다.
- (e) [미래 유망 토픽 해석] 포커스 영역의 토픽을 통한 미래 유망 토픽을 해석한다.

결론적으로 3차년도는 2차년도에서 제안한 AWSGCMC-BNTM과 AWSGCMC-BSR-BSS keyphrase 추출 알고리즘을 이용하여 대량의 텍스트 집합으로부터 미래 유망 토픽을 자동으로 탐지하는 프로세스 FADP를 제안하고자 한다.